

Analisi dell'architettura Temporal VAE

Stima e analisi del Value at Risk di un portfolio finanziario

Mattia Corigliano

Dipartimento di Ingegneria Informatica, Modellistica, Elettronica e Sistemistica
Università della Calabria, Arcavacata, Rende(CS) ←

18 gennaio 2026



- ➊ Introduzione e Contesto
- ➋ Analisi "Estimating the Value-at-Risk by Temporal VAE"
- ➌ Ricerca di un modello più robusto
- ➍ Analisi modelli su dataset più lungo

① Introduzione e Contesto

② Analisi "Estimating the Value-at-Risk by Temporal VAE"

③ Ricerca di un modello più robusto

④ Analisi modelli su dataset più lungo

Introduzione

In questa presentazione analizziamo l'architettura **Temporal VAE (TempVAE)**, proposta per la stima del **Value at Risk (VaR)** di un portafoglio finanziario. Il lavoro di riferimento è il paper *Estimating the Value-at-Risk by Temporal VAE*, di Robert Sicks, Stefanie Grimm, Ralf Korn e Ivo Richert (Department of Financial Mathematics, Fraunhofer ITWM).

Contesto

Il Problema: Value at Risk (VaR)

- Misura la perdita massima attesa di un investimento dato un livello di confidenza $(1 - \alpha)$ (es. 95%) e un orizzonte temporale.
- Domanda chiave: "Qual è la peggiore perdita che potrei subire (escludendo catastrofi)?".

Dai Modelli Classici al Deep Learning

- **Limiti GARCH:** Ipotesi rigide di normalità e difficoltà nel catturare non-linearità complesse.
- **Soluzione VAE:** Modelli generativi capaci di apprendere rappresentazioni latenti "comprese" e robuste, filtrando il rumore di mercato.
- **Adattabilità:** Le reti ricorrenti (RNN/GRU) catturano meglio la dipendenza temporale a lungo termine.

- 1 Introduzione e Contesto
- 2 Analisi "Estimating the Value-at-Risk by Temporal VAE"
- 3 Ricerca di un modello più robusto
- 4 Analisi modelli su dataset più lungo

Analisi paper di riferimento

Obiettivi dell'Analisi:

- 1 **Reverse Engineering:** Ricostruzione dell'architettura in assenza di codice pubblico.
- 2 **Validazione:** Replica dei risultati sul periodo 2018-2021.
- 3 **Ottimizzazione:** Miglioramento della stima del VaR tramite tuning degli iperparametri.

Modellazione:

- Serie dei rendimenti R generata da variabili latenti Z .
- Dipendenza temporale autoregressiva: il "mood" del mercato (Z_t) evolve basandosi sulla storia passata ($Z_{1:t-1}$).

Architettura del modello (TempVAE)

Il modello combina VAE e Reti Ricorrenti (GRU).


Encoder (Inferenza)

- **Bi-Directional GRU:** Estrae il contesto processando la sequenza sia in avanti che all'indietro.
- Mappa le osservazioni nella distribuzione a posteriori $q_{\phi}(Z|R)$.

Decoder (Generazione)

- **Prior "Congelata":** Rete non addestrabile per governare la dinamica latente (previene il Posterior Collapse).
- **Emissione:** Una GRU stima i parametri della distribuzione dei rendimenti.
- **Low-Rank Covariance:** Approssimazione $\Sigma = D + uu^T$ per efficienza computazionale.

Architettura del modello (TempVAE)



Encoder (Inferenza)

- Mappa i rendimenti storici in uno spazio latente a bassa dimensione (Z).
- Usa GRU bidirezionali per catturare contesto passato e futuro.

Spazio latente (Z)

- Rappresenta il *mood* del mercato (volatilità, panico, liquidità).
- Evoluzione autoregressiva: $Z_t \mid Z_{t-1}$.

Decoder (Emissione)

- Ricostruisce la distribuzione dei rendimenti futuri.
- Condiziona la generazione sullo stato latente.

Dettagli tecnici critici

Estrazione del contesto bidirezionale: una BiGRU che processa l'intera sequenza dei rendimenti osservati R , generando per ogni istante t una rappresentazione contestuale data dalla concatenazione degli stati nascosti forward e backward ($h_forward$, $h_backward$) per il contesto (*smoothing*), essenziale per comprendere shock strutturali.

Inferenza autoregressiva: GRUCell che fonde il contesto osservato con la memoria dello stato latente

Mappatura dei parametri e

regolarizzazione: un modulo MLP, nello spazio dei parametri μ_q e σ che definiscono la densità variazionale gaussiana.

```
class TempVAE(nn.Module):  
    def __init__(self, input_dim, latent_dim=10, hidden_dim=16, dropout=0.1):  
        """  
        Args:  
            input_dim (int): Dimensione dei rendimenti degli asset (d)  
            latent_dim (int): Dimensione dello spazio latente (kappa)  
            hidden_dim (int): Dimensione hidden per RNN e MLP (default 16)  
            dropout (float): Rate di dropout per le RNN (default 10%)  
        """  
        super(TempVAE, self).__init__()  
  
        self.input_dim = input_dim  
        self.latent_dim = latent_dim  
        self.hidden_dim = hidden_dim  
  
        # --- INFERENCE MODEL (Encoder) ---  
        # Eq (15) & (16): Bidirectional RNN per estrarre il contesto da R  
        # Input: R_t, Output: [h_forward, h_backward] (dimensione 2 * hidden_dim)  
        self.lnf_bi_rnn = nn.GRU(input_dim, hidden_dim, bidirectional=True, batch_first=True)  
        self.lnf_dropout = nn.Dropout(dropout)  
  
        # Eq (14): RNN inferenza autoregressiva  
        # Input: concat(h*2_{t-1}, z_{t-1}), Context_t)  
        # Context_t = l'output della BiGRU (2*hidden)  
        self.lnf_rnn_z = nn.GRUCell(latent_dim + 2 * hidden_dim, hidden_dim)  
  
        # Eq (13): MLP per parametri q(Z)  
        # Output: mu (kappa) + sigma_diag (kappa)  
        self.lnf_mlp = MLP(hidden_dim, latent_dim, hidden_dim)
```

Schema dell'Encoder.

Dettagli tecnici critici

Dinamica Latente e Prior "Congelata":

l'evoluzione dello stato latente $p_\theta(Z_t|Z_{t-1})$ è governata da una cella ricorrente (`gen_rnn_z`) seguita da un MLP(`gen_mlp_z`).

Modello di Emissione: La probabilità condizionata dei dati osservati $p_\theta(R_t|Z_{1:t})$ è data da una seconda catena ricorrente (`gen_rnn_r`).

Parametrizzazione Low-Rank della

Covarianza: l'aspetto più sofisticato del decoder risiede nella proiezione finale (`gen_mlp_r`) utilizzata per stimare la matrice di covarianza.

```
# --- GENERATIVE MODEL (Decoder) ---
# Eq (6): RNN Prior
# Input: Z_{t-1}, H_{t-1}
self.gen_rnn_z = nn.GRUCell(latent_dim, hidden_dim)

# Eq (5): MLP Prior
# Output: mu (kappa) + sigma_diag (kappa)
self.gen_mlp_z = MLP(hidden_dim, latent_dim, hidden_dim)

# Inizializzazione e Congelamento (Freeze) per Prior Fissa
for m in [self.gen_rnn_z, self.gen_mlp_z]:
    # Inizializzazione He
    for name, param in m.named_parameters():
        if 'weight' in name:
            nn.init.kaiming_normal_(param.data)
        elif 'bias' in name:
            nn.init.zeros_(param.data)

    # Congeliamo i pesi
    for param in m.parameters():
        param.requires_grad = False

# Eq (9): RNN Emissione
# Input: Z_t, H_{t-1}
self.gen_rnn_r = nn.GRUCell(latent_dim, hidden_dim)

# Eq (8): MLP Emissione
# Output per Rank-1 Perturbation:
# Diagonale D (input_dim)
# Vettore fattore u (input_dim) -> per uu^T trasposta
# Media mu (input_dim)
self.gen_mlp_r = nn.Sequential(
    nn.Linear(hidden_dim, hidden_dim),
    nn.ReLU(),
    nn.Linear(hidden_dim, input_dim * 3)
)
self.gen_dropout = nn.Dropout(dropout)
```

Schema del Decoder.

Setup sperimentale di replica (Baseline)

Dataset

- **Periodo:** 2018 – 2021.
- **Asset:**
 - SPY (Equity Global)
 - GLD (Oro/Safe Haven)
 - VIX (Volatilità)s
 - BTC (Crypto - High Volatility)


Preprocessing e Training

- Log-rendimenti per stazionarietà.
- Finestre scorrevoli ($M = 21$ giorni).
- Loss: ELBO (NLL + KL Divergence).

Metriche di Validazione:

- *Kupiec POF Test*: Accuratezza della frequenza delle violazioni.
- *Christoffersen Test*: Indipendenza seriale (assenza di clustering).

Risultato visivo



Backtesting visivo del VaR: rendimenti realizzati R_t e soglia dinamica. Negli shock negativi repentini il modello tende a reagire in modo non sempre coerente: in prossimità della prima violazione (indicata con X) la soglia aumenta invece di diventare più conservativa, e un comportamento analogo si osserva in presenza delle successive spike.

Analisi Baseline: Successo o Illusione?

Risultati Quantitativi :

- Violazioni osservate: 17 (Attese: 16.1).
- Kupiec P-Value: $0.82 \gg 0.05$ (Modello statisticamente valido).

Criticità Empiriche (Over-smoothing) :

- **Scarsa Reattività:** Il VaR reagisce in modo incoerente agli shock negativi (es. aumenta invece di diminuire).
- **Rigidità:** Irrigidimento della soglia durante fluttuazioni moderate.
- **Causa:** Iperparametri che favoriscono una stima della varianza troppo "piatta" e conservativa.

- 1 Introduzione e Contesto
- 2 Analisi "Estimating the Value-at-Risk by Temporal VAE"
- 3 Ricerca di un modello più robusto
- 4 Analisi modelli su dataset più lungo

Selezione iperparametri: Optuna to Sensitivity Analysis

Limiti dell'Ottimizzazione Bayesiana

L'approccio iniziale con **Optuna** adottando la strategia *Tree-structured Parzen Estimator* ha prodotto risultati non generalizzabili:

- Fenomeno di *Data Leakage* nella TimeSeriesSplit.
- **Overfitting:** NLL bassa in validazione ma fallimento totale nei test di backtesting (Kupiec e Christoffersen $p = 0.00$).

Optando per una **Sensitivity Analysis sequenziale**, variando un parametro alla volta su 3 modelli con caratteristiche differenti sono stati evidenziati gli iperparametri migliori. I 3 modelli sono : TempVAE, TempVAE senza L2, TempVAE senza L2 e Dropout.

Strategia di Ottimizzazione (Modello Tuned)

Lo studio di questi 3 modelli ha portato alla conferma che il modello **senza L2** risulta esser il migliore. Infatti la rimozione della regolarizzazione L2 è stata decisiva. Con L2 attiva, il modello "lasciava" troppo la varianza, causando *clustering* delle violazioni (fallimento test Christoffersen). Senza L2, la calibrazione dinamica è corretta. Gli iperparametri migliori trovati dopo una serie di esecuzioni di training sono stati:

Parametro	Baseline	Tuned	Motivazione
Regolarizzazione L2	0.01	0.0	Rimuove il bias verso la media, sbloccando la reattività agli shock.
Finestra (T)	21 gg	28 gg	Cattura la ciclicità mensile completa.
Hidden Dim	16	26	Aumenta la capacità per gestire la curiosità di BTC.
Batch Size	256	140	Introduce rumore stocastico per evitare minimi locali.

Confronto Prestazioni (2018-2021)

Il modello Tuned migliora drasticamente il fit distributivo :

Metrica	Baseline	Tuned (Proposto)
Hit Rate (Target 5%)	5.28%	6.03%
NLL (Fit ai dati)	≈ 43.3	≈ 17.3 (Migliore)
KL Divergence	≈ 74	≈ 128 (Latenti attive)
Kupiec Test	Passato ($p = 0.82$)	Passato ($p = 0.41$)

Nota: Una NLL più bassa indica che il modello ha imparato una distribuzione che si adatta meglio ai dati reali (code pesanti), non solo alla media.

Confronto visivo

VaR Comparison with Refined Zooms - BTC, SPY, GLD e VIX 2018-21





Figura 1: Zoom sul confronto tra VaR stimato e rendimenti: dettaglio delle violazioni e della reattività ai cambi di regime.

Analisi Spazio Latente: Disentanglement

Il modello Tuned attiva dimensioni latenti interpretabili:

- Z_2 (Risk-On / Sentiment):
 - Correlazione positiva con SPY (+0.58) e BTC (+0.56), negativa con VIX (-0.66).
 - Rappresenta l'appetito per il rischio sistemico "Risk-On/Risk-Off".
- Z_7 (Crypto-Specific Momentum):
 - Correlato quasi esclusivamente con BTC (+0.78).
 - Isola i movimenti crypto dai driver macroeconomici.
- Z_3 (Safe Haven Volatility):
 - Guidato dalla volatilità dell'Oro (+0.44) e altre volatilità.

Segnale incertezza macroeconomica



Heatmap delle correlazioni tra variabili osservate X_i e latenti Z_j .

Descrizione del Dataset Esteso (2004-2025)

Orizzonte Temporale

- **Periodo:** Gen 2004 – Dic 2025.
- *Nota:* Esclusione di Bitcoin (BTC-USD) per limitata profondità storica (dati disponibili solo dal ~2014), al fine di garantire una serie completa senza dati mancanti.

Implicazioni per la Ricerca

- Transizione da analisi episodica a **validazione rigorosa**.
- Stress test del modello su crisi strutturalmente diverse:
 - Crisi Finanziaria Globale (2008).
 - Repricing Obbligazionario(2022).

Universo Investibile

1. Equity (Driver di Rischio)

- SPY (S&P 500)
- QQQ (Nasdaq 100)
- IWM (Russell 2000)
- EEM (Emerging Mkts)
- XLF (Financials)
- XLE (Energy)

2. Diversificatori

- TLT (Treasury 20+ Year)
- GLD (Gold)

3. Sentiment

- $\sqrt{VIX}$ (Volatilità Implicita)

- 1 Introduzione e Contesto
- 2 Analisi "Estimating the Value-at-Risk by Temporal VAE"
- 3 Ricerca di un modello più robusto
- 4 Analisi modelli su dataset più lungo

Analisi dello Spazio Latente (Modello Tuned)






Figura 2: Latent Space Semantic Map (2004–2025): visualizzazione delle correlazioni tra feature osservate e componenti latenti.

Interpretabilità delle Features: Disentanglement

Il modello *Tuned* dimostra una superiore capacità di isolare specifici driver economici in variabili distinte:

- z_1 – **Fattore Azionario Sistemico (Market Mode):**
Rappresenta il "Beta" del portafoglio. Mostra correlazioni molto elevate (> 0.85) con un ampio spettro di indici globali (EEM), Small Cap (IWM) e settoriali (Energia, Finanza).
- z_3 – **Fattore Safe-Haven (Flight-to-Quality):** Cattura le dinamiche di avversione al rischio. È correlato esclusivamente con asset difensivi come l'Oro (GLD, $\rho \approx 0.64$) e i Treasury a lungo termine (TLT).
- z_6 – **Fattore Indici Globali / Large Cap:** Si distingue da z_1 isolando le dinamiche specifiche delle grandi capitalizzazioni e del settore Tech. Presenta correlazioni mirate con il Nasdaq (QQQ) e l'S&P 500.

Robustezza Longitudinale (2004-2025)



Risultati Stress Testing

- **Covid Crash (2020):** Il modello Tuned adatta il VaR immediatamente al crollo; il Baseline rimane statico.
- **Bear Market (2022):** Il modello Tuned segue le oscillazioni con maggiore fedeltà, offrendo una copertura dinamica.
- **Confronto:** Il modello Tuned produce stime di VaR più prudenti (negative) durante i drawdown, catturando meglio il *tail risk*.

Conclusioni: Dal Baseline al Tuned Model

Validazione e Limiti:

- Il modello *Baseline* (replica) è valido sul breve periodo, ma fallisce sul dataset esteso (2004-2025).
- **Problema critico:** Fallimento del test di Christoffersen ($p < 0.05$), indicando "cluster di violazioni" non gestiti durante gli stress di mercato.

Il Modello Ottimizzato (Tuned): Modifiche architetturali mirate per garantire resilienza operativa:

- ➊ **Sequence Length** ($21 \rightarrow 28$): Cattura completa dei cicli di volatilità mensile.
- ➋ **Hidden Dim** ($16 \rightarrow 26$): Maggiore capacità per modellare le code non lineari.
- ➌ **Batch Size** ($256 \rightarrow 140$): Regolarizzazione implicita tramite SGD.

Risultato: Superamento di entrambi i test (Kupiec e Christoffersen) e adattamento dinamico superiore.

Sviluppi Futuri

Alla luce dei risultati, si propongono quattro direzioni di ricerca:

Evoluzione del Modello

- **Spazio Latente Non-Gaussiano:** Uso di priori t-Student o misture per modellare esplicitamente le *fat tails*.
- **Meccanismi di Attention:** Integrazione della Self-Attention per pesare dinamicamente gli shock storici rilevanti.

Applicazioni Finanziarie

- **Asset Digitali:** Validazione specifica su mercati ad alta frequenza (Criptovalute).
- **Allocazione Dinamica:** Utilizzo dello spazio latente per l'asset selection attiva e ottimizzazione Mean-CVaR / Risk Parity.